Modelagem Preditiva da Solubilidade Química: Uma Análise Comparativa entre Regressão Linear, Regularizada (Ridge), PLS e Redes Neurais

1st David Baima Monte
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
davidbmonte@alu.ufc.br

2nd Diego Mendes de Freitas
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
mendesdiego@alu.ufc.br

3rd Gustavo Moraes Teles
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
gustavvomt@gmail.com

4th Rafael Martins Guimarães Vieira
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
rafamgv004@gmail.com

***Resumo*—A estimativa precisa da solubilidade de compostos químicos desempenha um papel fundamental no desenvolvimento de novos fármacos e materiais. Este trabalho apresenta um estudo comparativo entre métodos de aprendizado de máquina para prever a solubilidade química a partir de um conjunto de dados composto por $N = 1267$ observações e $D = 228$ preditores (208 *fingerprints* binárias e 20 descritores moleculares). Para atenuar a assimetria e o mau condicionamento decorrentes da colinearidade severa entre os preditores, aplicou-se a transformação de Yeo-Johnson aos descritores contínuos e de contagem. Foram avaliados quatro algoritmos implementados e validados por validação cruzada em 10 partições: Mínimos Quadrados Ordinários (OLS), Regressão Ridge, Mínimos Quadrados Parciais (PLS) e Perceptron de Múltiplas Camadas (MLP). Os resultados indicam que o modelo não linear MLP ($h = 5, \alpha = 10$) superou as abordagens lineares, atingindo a menor Raiz do Erro Quadrático Médio (RMSE $= 0{,}637$) e o maior coeficiente de determinação ($R^2 = 0{,}906$) no conjunto de teste de 316 amostras. Entre os modelos lineares, a regressão Ridge ($\lambda = 34{,}8$) obteve o melhor desempenho (RMSE $= 0{,}717$; $R^2 = 0{,}881$), evidenciando a eficácia do tratamento de multicolinearidade e a presença de relações não lineares e interações estruturais na predição da solubilidade.**

***Index Terms*—Solubilidade Química, Regressão Ridge, Mínimos Quadrados Parciais (PLS), Redes Neurais (MLP), Quimioinformática.**

I. Introdução

A previsão de propriedades físico-químicas, como a solubilidade em água, é uma etapa essencial no planejamento de compostos químicos e no desenvolvimento de biofarmacêuticos, influenciando diretamente a absorção e a biodisponibilidade de fármacos. Tradicionalmente expressa em termos moleculares, a solubilidade depende de uma interrelação complexa entre subestruturas químicas, distribuição de carga, peso molecular e área de superfície. Com o avanço das abordagens computacionais de quimioinformática, modelos preditivos baseados em aprendizado de máquina têm sido amplamente empregados para estimar essas propriedades a partir de representações estruturais como descritores moleculares e *fingerprints*.

Entretanto, a construção de modelos preditivos eficazes nessa área enfrenta desafios estatísticos significativos, como o mau condicionamento das matrizes de preditores induzido por alta multicolinearidade e o risco de sobreajuste devido ao elevado número de variáveis em relação à quantidade de amostras. Para contornar essas limitações, estratégias de regularização como a Regressão Ridge e técnicas de redução de dimensionalidade supervisionada como os Mínimos Quadrados Parciais (PLS) oferecem suporte robusto ao lidar com variáveis correlacionadas. Adicionalmente, considerando que a relação entre a estrutura molecular e a solubilidade nem sempre se comporta de forma estritamente aditiva, a utilização de aproximações não lineares por meio de redes neurais artificiais (como o Perceptron de Múltiplas Camadas) torna-se uma alternativa promissora para capturar interações complexas entre os descritores.

Este trabalho tem como objetivo comparar o desempenho de modelos lineares e não lineares na tarefa de regressão da solubilidade química. Especificamente, avaliam-se o modelo de Mínimos Quadrados Ordinários (OLS), a Regressão Ridge, a Regressão por Mínimos Quadrados Parciais (PLS) e uma Rede Neural MLP. O pipeline experimental contempla o pré-processamento de dados via transformação de Yeo-Johnson para correção de assimetria, a calibração de hiperparâmetros por validação cruzada em 10 partições e a comparação detalhada dos erros de generalização no conjunto de teste.

II. MÉTODOS

A. Dados e pré-processamento

Utilizou-se o conjunto de dados de solubilidade de compostos químicos descrito em [1], com $N = 1267$ observações e $D = 228$ preditores, divididas em 951 amostras de treino e 316 de teste. Os preditores compreendem 208 variáveis binárias (*fingerprints*, FP) que indicam a presença ou ausência de subestruturas químicas, 16 descritores de contagem (como o número de ligações e de átomos de bromo) e 4 descritores contínuos (peso molecular e medidas de área de superfície). A variável de saída é a solubilidade do composto. Não há valores ausentes no conjunto.

A assimetria de cada preditor foi quantificada pelo coeficiente de assimetria amostral, com o estimador corrigido para viés (função `skew` do SciPy com `bias=False`). Para uma variável binária, a assimetria depende exclusivamente da proporção p de valores iguais a 1, e qualquer transformação monótona apenas reatribui rótulos aos dois níveis, sem alterar a forma da distribuição. Por essa razão, as 208 FPs foram mantidas sem transformação, e a correção foi aplicada aos 20 descritores de contagem e contínuos. Como vários desses descritores contêm zeros e um deles (`HydrophilicFactor`) assume valores negativos, adotou-se a transformação de Yeo-Johnson [2], que dispensa a exigência de positividade estrita do Box-Cox. Os parâmetros de transformação λ foram estimados exclusivamente no conjunto de treino e aplicados ao conjunto de teste com os mesmos valores, evitando vazamento de informação.

B. Regressão linear por mínimos quadrados ordinários

No modelo linear, a resposta é aproximada por $\hat{y} = \beta_0 + \sum_{j=1}^{D} \beta_j x_j$, e os coeficientes são obtidos minimizando a soma dos quadrados dos resíduos. Com a matriz de projeto $\mathbf{A}$ (preditores transformados acrescidos de uma coluna de uns para o intercepto), a solução satisfaz as equações normais, $\mathbf{A}^\top \mathbf{A}\,\boldsymbol{\beta} = \mathbf{A}^\top \mathbf{y}$. O método é simples, rápido e interpretável, mas sofre com a colinearidade entre preditores, que torna $\mathbf{A}^\top \mathbf{A}$ mal condicionada e as estimativas instáveis, e com o sobreajuste quando o número de parâmetros é grande em relação ao de observações.

O estimador foi implementado do zero em duas versões: pela resolução direta das equações normais (sistema linear, sem inversão explícita) e por um solver de mínimos quadrados baseado em decomposição matricial (`numpy.linalg.lstsq`), numericamente mais estável. Os resultados foram comparados com a função `LinearRegression` da biblioteca scikit-learn [3]. O desempenho foi medido pela raiz do erro quadrático médio (RMSE) e pelo coeficiente de determinação, $R^2 = 1 - \sum_i (y_i - \hat{y}_i)^2 / \sum_i (y_i - \bar{y})^2$.

Para estimar o erro de generalização, empregou-se validação cruzada com 10 partições, também implementada do zero. Como os valores de solubilidade no conjunto de treino não estão embaralhados, os índices foram permutados aleatoriamente (semente fixa) antes da divisão. As mesmas partições foram reutilizadas para todos os modelos, o que permite comparações pareadas entre eles, e foram também fornecidas à função de validação cruzada da biblioteca para a verificação da implementação.

C. Regressão ridge

A regressão ridge [4] acrescenta ao critério de mínimos quadrados uma penalidade sobre a norma euclidiana dos coeficientes,

$$\hat{\boldsymbol{\beta}}_\lambda = \arg\min_{\boldsymbol{\beta}} \; \|\mathbf{y} - \mathbf{Z}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2, \tag{1}$$

cuja solução em forma fechada é $\hat{\boldsymbol{\beta}}_\lambda = (\mathbf{Z}^\top \mathbf{Z} + \lambda \mathbf{I})^{-1} \mathbf{Z}^\top \mathbf{y}$. Ao somar $\lambda \mathbf{I}$ à matriz $\mathbf{Z}^\top \mathbf{Z}$, o problema fica bem condicionado mesmo na presença de preditores colineares, ao custo de um viés controlado pelo parâmetro $\lambda \geq 0$, que reduz a variância das estimativas (com $\lambda = 0$ recupera-se o OLS). Como desvantagens, o método não zera coeficientes, isto é, não realiza seleção de variáveis como a penalização L_1, e seu resultado depende da escala dos preditores, de modo que é necessário padronizá-los.

Na implementação do zero, os preditores foram padronizados (média nula e desvio padrão unitário, com colunas de variância nula mantidas sem escala), a resposta foi centrada e o intercepto não foi penalizado, sendo recuperado a partir da média da resposta. A média e o desvio padrão usados na padronização foram calculados sempre apenas sobre os dados de treino de cada partição e, no ajuste final, sobre o conjunto de treino completo, e reaplicados ao conjunto de validação ou de teste. O parâmetro λ foi escolhido por validação cruzada com 10 partições, usando apenas o conjunto de treino e as mesmas partições do item anterior, sobre uma grade de 25 valores espaçados logaritmicamente entre 10^{-2} e 10^{3}, selecionando-se o valor de menor RMSE médio. O modelo final foi reajustado em todo o conjunto de treino com o λ escolhido e avaliado no conjunto de teste. A implementação foi comparada com a classe `Ridge` da biblioteca scikit-learn [3], encadeada a um padronizador, tanto no perfil de validação cruzada quanto nas predições de teste.

D. Regressão por mínimos quadrados parciais

A regressão por mínimos quadrados parciais (PLS) [5], [6] lida com preditores numerosos e correlacionados projetando-os em um número reduzido k de componentes ortogonais, $\mathbf{T} = \mathbf{Z}\mathbf{W}$, sobre os quais a resposta é regredida por mínimos quadrados. Diferentemente da regressão por componentes principais (PCR), em que as componentes são escolhidas apenas pela variância dos preditores, no PLS cada direção $\mathbf{w}$ é construída de modo a maximizar a covariância entre a projeção dos preditores e a resposta, de forma que as primeiras componentes tendem a ser as mais informativas para a predição. As vantagens são a robustez à colinearidade e a redução de dimensionalidade, e a principal desvantagem é a necessidade de escolher k: poucas componentes produzem subajuste, e muitas aproximam o modelo do OLS, com sobreajuste. Como o PLS também depende da escala, os preditores foram padronizados.

Foi implementado do zero o algoritmo NIPALS para resposta univariada: em cada iteração, calcula-se $\mathbf{w} \propto \mathbf{Z}^\top \mathbf{y}$, o escore $\mathbf{t} = \mathbf{Z}\mathbf{w}$, as cargas $\mathbf{p} = \mathbf{Z}^\top \mathbf{t}/(\mathbf{t}^\top \mathbf{t})$ e o coeficiente $q = \mathbf{y}^\top \mathbf{t}/(\mathbf{t}^\top \mathbf{t})$, e ambos $\mathbf{Z}$ e $\mathbf{y}$ são deflacionados antes da componente seguinte. Os coeficientes finais, expressos nas variáveis originais padronizadas, são $\mathbf{B} = \mathbf{W}(\mathbf{P}^\top \mathbf{W})^{-1}\mathbf{q}$. A padronização foi calculada, em cada partição, apenas sobre os dados de treino e reaplicada à validação e ao teste. O número de componentes foi escolhido entre 1 e 40 por validação cruzada com 10 partições, sobre o conjunto de treino e com as mesmas partições dos itens anteriores, adotando-se o valor de menor RMSE médio. O modelo foi então reajustado em todo o conjunto de treino e avaliado no teste. A implementação foi comparada com a classe `PLSRegression` da biblioteca scikit-learn [3], aplicada aos mesmos dados padronizados.

E. Rede neural para regressão

Para capturar possíveis relações não lineares e interações entre os preditores, utilizou-se uma rede neural do tipo perceptron de múltiplas camadas, com uma camada oculta de h neurônios com função de ativação ReLU e saída linear, treinada pela minimização do erro quadrático acrescido de uma penalidade L_2 sobre os pesos (decaimento de pesos, controlado por α) [7]. Pela capacidade de aproximar funções complexas, esse tipo de modelo pode superar os modelos lineares quando há não linearidades, mas, em contrapartida, é mais custoso, sensível à inicialização e aos hiperparâmetros, propenso ao sobreajuste e pouco interpretável. Utilizou-se a implementação `MLPRegressor` da biblioteca scikit-learn [3], com o otimizador L-BFGS [8] e limite de 300 iterações. Os preditores transformados foram padronizados, assim como a resposta, com médias e desvios padrão calculados apenas no conjunto de treino, e as predições foram convertidas de volta à escala original. Para reduzir a variabilidade decorrente da inicialização aleatória dos pesos, cada modelo é a média das predições de três redes treinadas com sementes distintas.

Os hiperparâmetros h e α foram escolhidos por validação cruzada com 10 partições, usando apenas o conjunto de treino e as mesmas partições dos itens anteriores, sobre a grade $h \in \{2, 3, 5\}$ e $\alpha \in \{10, 30, 100\}$, selecionando-se a combinação de menor RMSE médio. O modelo foi então reajustado em todo o conjunto de treino e avaliado no teste. Para comparar a rede com os modelos lineares, aplicaram-se testes pareados (teste t e teste de Wilcoxon) aos RMSE obtidos nas 10 partições, que são comuns a todos os modelos.

III. Resultados

A. Análise exploratória

Antes da transformação, todos os 20 descritores apresentavam assimetria positiva, com valores entre 0,67 (`NumMultBonds`) e 3,85 (`NumSulfer`). Após a transformação, a maioria passou a ter assimetria em módulo inferior a 0,3. Por exemplo, `HydrophilicFactor` passou de 3,41 para 0,25 (Tabela I e Fig. 1). Permaneceram assimétricos `NumSulfer` (2,24), `NumChlorine` (1,42) e `NumHalogen` (1,01), colunas dominadas por zeros, nas quais nenhuma transformação monótona consegue dispersar a massa de valores idênticos.

Tabela I
Assimetria de descritores selecionados antes e depois da transformação de Yeo-Johnson, com o parâmetro λ estimado no treino.

Descritor	Antes	Depois	λ
`HydrophilicFactor`	3,41	0,25	$-0{,}32$
`SurfaceArea1`	1,72	$-0{,}24$	0,35
`MolWeight`	0,99	0,00	0,00
`NumCarbon`	0,93	0,00	0,25
`NumSulfer`	3,85	2,24	$-9{,}77$
`NumChlorine`	3,18	1,42	$-3{,}63$
`NumHalogen`	2,70	1,01	$-2{,}53$

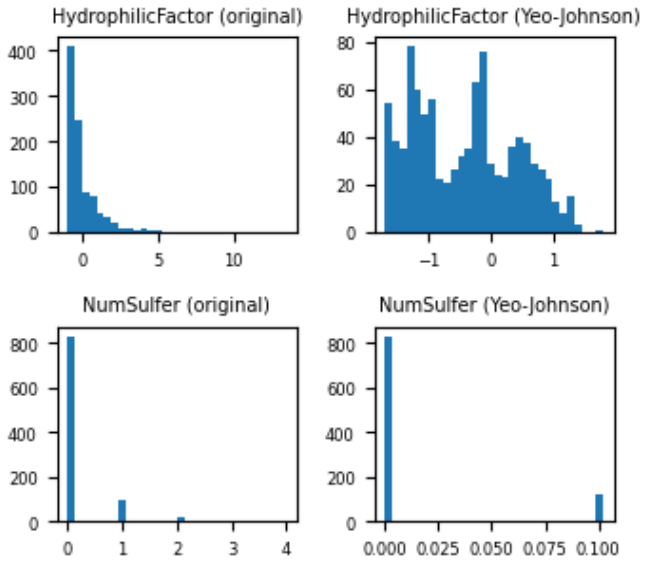


Figura 1. Distribuição de `HydrophilicFactor` e `NumSulfer` antes (esquerda) e depois (direita) da transformação de Yeo-Johnson.

A matriz de correlação entre os 228 preditores transformados revela colinearidade expressiva: dos 25.878 pares distintos, 47 têm $|r| > 0{,}9$ e 176 têm $|r| > 0{,}75$. Parte dessas relações tem interpretação química direta, como a correlação de 0,997 entre o número de átomos (`NumAtoms`) e o de ligações (`NumBonds`), mostrada na Fig. 2 para os descritores não binários. Há também pares envolvendo fingerprints e descritores de contagem, como FP134 e `NumSulfer` ($r = 1{,}000$) e FP107 e `NumChlorine` ($r = 0{,}999$), o que indica informação redundante.

Quanto à relação entre cada preditor e a solubilidade, as correlações de Pearson mais fortes são todas negativas, sendo a maior em módulo a de `MolWeight` ($r = -0{,}659$), seguida de `NumCarbon` ($-0{,}607$) e `NumNonHBonds` ($-0{,}585$), o que indica menor solubilidade em moléculas maiores. A média de $|r|$ foi 0,402 nos descritores contínuos, 0,349 nos de contagem e apenas 0,122 nas FPs, de modo que nenhum preditor isolado explica mais de cerca de 43% da variância da resposta. Nos descritores, o coeficiente de Spearman foi

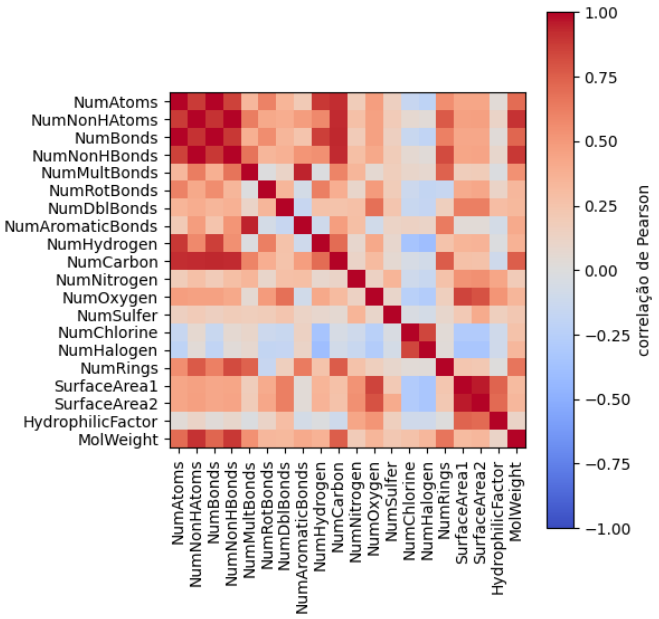


Figura 2. Correlação de Pearson entre os 20 descritores não binários após a transformação.

sistematicamente maior em módulo que o de Pearson (por exemplo, $-0{,}674$ contra $-0{,}607$ em `NumCarbon`), o que sugere relações monótonas, porém não estritamente lineares.

B. Regressão linear por mínimos quadrados

O modelo de mínimos quadrados ajustado no conjunto de treino apresentou RMSE de 0,490 sobre os próprios dados de treino e de 0,743 no conjunto de teste, com $R^2 = 0{,}872$ (Tabela II). As duas implementações do zero e a da biblioteca produziram as mesmas predições, com diferenças máximas da ordem de 10^{-12} para o solver de decomposição, e a maior diferença entre os coeficientes foi de cerca de 2×10^{-9}. Apesar de a matriz de preditores ter posto completo, seu número de condição (cerca de $1{,}8\times10^{6}$) confirma o mau condicionamento discutido na análise exploratória.

A validação cruzada com 10 partições resultou em RMSE médio de 0,728 (desvio padrão entre partições de 0,067) e R^2 médio de 0,865. As estimativas obtidas com a implementação do zero e com a biblioteca, nas mesmas partições, diferiram em no máximo 2×10^{-11} no RMSE por partição. O RMSE de validação cruzada é próximo do obtido no teste (0,728 contra 0,743), diferença bem inferior à variabilidade entre partições, o que indica que a validação cruzada fornece uma estimativa confiável do desempenho em dados novos. Já o RMSE de treino (0,490) é substancialmente menor, evidenciando sobreajuste, compatível com o uso de 228 preditores para 951 observações.

A necessidade de embaralhar as observações antes da divisão foi verificada empiricamente. Com partições contíguas, o RMSE médio foi de 0,762, mas o R^2 por partição variou de $-10{,}3$ a 0,85 (média de $-3{,}5$), pois várias partições cobrem apenas uma faixa estreita de solubilidade e, nelas, a variância

Tabela II
DESEMPENHO DO MODELO DE MÍNIMOS QUADRADOS ORDINÁRIOS (RMSE E R^2). NA VALIDAÇÃO CRUZADA, VALORES MÉDIOS DAS 10 PARTIÇÕES (DESVIO PADRÃO ENTRE PARÊNTESES).

Avaliação	RMSE	R^2
Validação cruzada (10 partições)	0,728 (0,067)	0,865
Teste (316 observações)	0,743	0,872

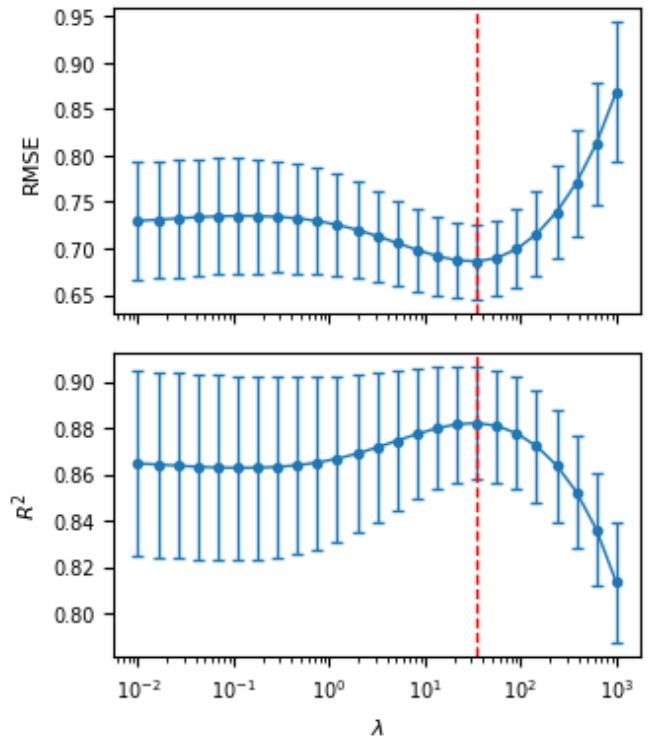


Figura 3. Perfil de validação cruzada (10 partições) da regressão ridge em função de λ: RMSE (acima) e R^2 (abaixo), com média e desvio padrão entre as partições. A linha tracejada marca o λ selecionado.

total que serve de referência é pequena. O RMSE é, portanto, a métrica mais robusta para comparar modelos, e os valores de R^2 por partição devem ser interpretados com cautela.

C. Regressão ridge

O perfil de validação cruzada (Fig. 3) mostra que, para λ pequeno, o RMSE é praticamente o do modelo sem penalização (cerca de 0,73) e permanece aproximadamente constante até $\lambda \approx 1$. Em seguida diminui até um mínimo em $\lambda \approx 34{,}8$ e volta a crescer para valores maiores, à medida que a penalização passa a introduzir viés excessivo. O R^2 acompanha o RMSE de forma inversa. No mínimo, o RMSE de validação cruzada foi 0,686 (desvio padrão entre partições de 0,041) e o R^2 médio 0,882, contra 0,728 e 0,865 do modelo sem penalização. Como λ foi escolhido sobre esses mesmos dados, essa estimativa é ligeiramente otimista, e a avaliação no conjunto de teste, que não participou da escolha, é a referência mais confiável.

Tabela III
COMPARAÇÃO ENTRE OLS E REGRESSÃO RIDGE. VALIDAÇÃO CRUZADA COM 10 PARTIÇÕES (MÉDIA E DESVIO PADRÃO DO RMSE) E CONJUNTO DE TESTE.

Modelo	Validação cruzada		Teste	
	RMSE	R^2	RMSE	R^2
OLS	0,728 (0,067)	0,865	0,743	0,872
Ridge ($\lambda = 34{,}8$)	0,686 (0,041)	0,882	0,717	0,881

No conjunto de teste, o modelo ridge com $\lambda \approx 34{,}8$ obteve RMSE de 0,717 e R^2 de 0,881, ante 0,743 e 0,872 do OLS (Tabela III), uma redução de cerca de 3,5% no RMSE. O RMSE de treino subiu de 0,490 (OLS) para 0,547, e a distância em relação ao erro de teste diminuiu, o que é coerente com a redução do sobreajuste. A implementação do zero e a da biblioteca coincidiram com precisão numérica: a maior diferença entre os RMSE por partição ao longo de toda a grade foi de cerca de 6×10^{-13}, e a maior diferença entre as predições de teste foi de cerca de 4×10^{-14}. Verificou-se ainda que, com λ próximo de zero, a implementação reproduz o RMSE de teste do OLS (0,743).

D. Regressão por mínimos quadrados parciais

O perfil de validação cruzada (Fig. 4) mostra um erro muito elevado com poucas componentes (RMSE médio de 1,29 com uma componente), que cai rapidamente até cerca de 10 componentes (0,72) e forma um patamar em torno de 0,705 a 0,71 entre 14 e 22 componentes. O mínimo ocorre com 19 componentes, com RMSE médio de 0,705 (desvio padrão entre partições de 0,050) e R^2 médio de 0,875. Para mais componentes, o erro volta a crescer lentamente, à medida que o modelo incorpora direções de pouca relevância preditiva. Como o patamar é largo, valores de k próximos do mínimo são praticamente equivalentes. Aplicando a regra do erro padrão, que escolhe o menor k cujo RMSE médio esteja dentro de um erro padrão do mínimo, obter-se-ia $k = 11$, com RMSE de validação cruzada de 0,721, o que representa uma alternativa mais parcimoniosa. Neste trabalho, adotou-se o critério do menor RMSE, $k = 19$, definido no enunciado.

No conjunto de teste, o modelo com 19 componentes obteve RMSE de 0,734 e R^2 de 0,875 (Tabela IV), resultado melhor que o do OLS (0,743), porém inferior ao da regressão ridge (0,717). O RMSE de treino foi de 0,538, intermediário entre o do OLS (0,490) e o do ridge (0,547). O modelo resume, assim, os 228 preditores em 19 componentes sem perda relevante de desempenho em relação aos demais modelos lineares. A implementação do zero e a da biblioteca coincidiram até a precisão numérica: a maior diferença entre os RMSE por partição ao longo de toda a faixa de componentes foi de cerca de 3×10^{-15}, e a das predições de teste, cerca de 9×10^{-15}.

E. Rede neural e comparação entre os modelos

A Tabela V mostra o RMSE médio de validação cruzada para cada combinação de hiperparâmetros. O desempenho depende fortemente do decaimento de pesos: com $\alpha = 100$ a rede fica excessivamente regularizada (RMSE de 0,71 a 0,72

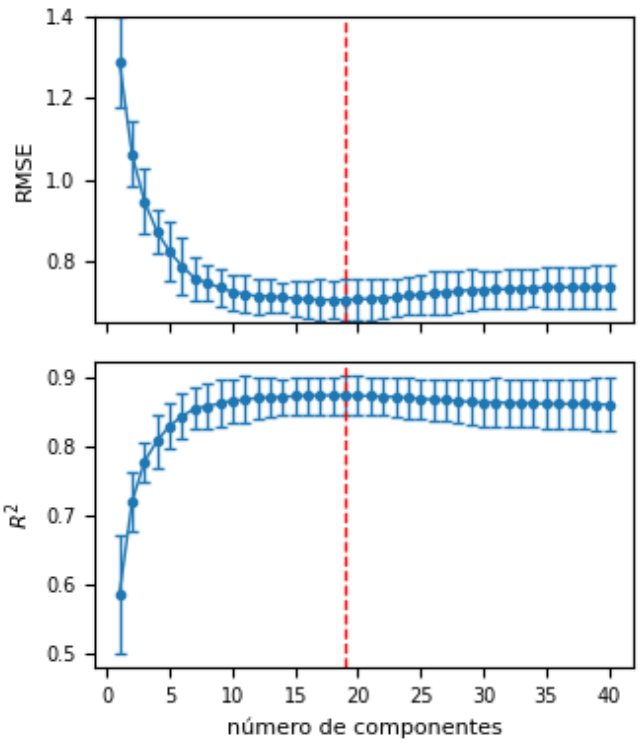


Figura 4. Perfil de validação cruzada (10 partições) da regressão PLS em função do número de componentes: RMSE (acima) e R^2 (abaixo), com média e desvio padrão entre as partições. A linha tracejada marca o número de componentes selecionado.

Tabela IV
COMPARAÇÃO ENTRE OS MODELOS LINEARES. VALIDAÇÃO CRUZADA COM 10 PARTIÇÕES (MÉDIA E DESVIO PADRÃO DO RMSE) E CONJUNTO DE TESTE.

Modelo	Validação cruzada		Teste	
	RMSE	R^2	RMSE	R^2
OLS	0,728 (0,067)	0,865	0,743	0,872
Ridge ($\lambda = 34{,}8$)	0,686 (0,041)	0,882	0,717	0,881
PLS ($k = 19$)	0,705 (0,050)	0,875	0,734	0,875

para qualquer h), enquanto valores intermediários produzem os melhores resultados. A melhor combinação foi $h = 5$ e $\alpha = 10$, com RMSE médio de 0,608 (desvio padrão entre partições de 0,063).

No conjunto de teste, a rede obteve RMSE de 0,637 e R^2 de 0,906, contra 0,717 e 0,881 do melhor modelo linear (ridge), 0,734 e 0,875 do PLS e 0,743 e 0,872 do OLS (Tabela VI). A redução do RMSE de teste em relação ao ridge foi de cerca de 11%. O RMSE de treino da rede (0,279) é muito inferior ao de teste, o que mostra grande capacidade de ajuste e que o desempenho depende da regularização, mas, ainda assim, o erro em dados novos é o menor entre todos os modelos. A vantagem se repete na validação cruzada (0,608 contra 0,686 do ridge, 0,705 do PLS e 0,728 do OLS). Nos testes pareados sobre os RMSE por partição, a diferença entre a rede e cada modelo linear foi [TODO: indicar sentido e p-valores do teste t e do Wilcoxon para OLS, ridge e PLS].

Tabela V
RMSE MÉDIO DE VALIDAÇÃO CRUZADA (10 PARTIÇÕES) DA REDE NEURAL EM FUNÇÃO DO NÚMERO DE NEURÔNIOS h E DO DECAIMENTO DE PESOS α.

	$\alpha = 10$	$\alpha = 30$	$\alpha = 100$
$h = 2$	0,644	0,647	0,718
$h = 3$	0,649	0,644	0,712
$h = 5$	**0,608**	0,627	0,712

Tabela VI
COMPARAÇÃO ENTRE OS MODELOS. VALIDAÇÃO CRUZADA COM 10 PARTIÇÕES (MÉDIA E DESVIO PADRÃO DO RMSE) E CONJUNTO DE TESTE.

Modelo	Validação cruzada		Teste	
	RMSE	R^2	RMSE	R^2
OLS	0,728 (0,067)	0,865	0,743	0,872
Ridge ($\lambda = 34{,}8$)	0,686 (0,041)	0,882	0,717	0,881
PLS ($k = 19$)	0,705 (0,050)	0,875	0,734	0,875
Rede neural ($h = 5$, $\alpha = 10$)	0,608 (0,063)	–	0,637	0,906

Como as partições compartilham observações de treino, esses p-valores são aproximados, e como a configuração da rede foi escolhida sobre essas mesmas partições, sua vantagem na validação cruzada é ligeiramente otimista; a comparação no conjunto de teste, que não participou de nenhuma escolha, é a mais confiável.

O modelo não linear superou os lineares, o que sugere que parte da relação entre os preditores e a solubilidade não é capturada por efeitos aditivos e lineares. Isso é coerente com os indícios da análise exploratória, em que correlações de Spearman maiores que as de Pearson e a curvatura observada em descritores como as áreas de superfície apontavam relações monótonas, mas não lineares. É plausível também que existam interações entre subestruturas químicas e descritores moleculares, que um modelo aditivo não representa. A análise realizada, porém, não permite identificar quais não linearidades ou interações respondem pelo ganho, nem separar o efeito da não linearidade do efeito da regularização aplicada à rede.

1) Limitações: Os resultados da rede devem ser lidos com algumas ressalvas. Primeiro, a busca de hiperparâmetros foi restrita a uma grade pequena, por custo computacional, e a melhor combinação ($h = 5$) está na borda da grade quanto ao número de neurônios, de modo que configurações maiores, não exploradas, podem apresentar desempenho ainda melhor, e o valor reportado deve ser entendido como uma estimativa conservadora do que a rede pode alcançar. Segundo, o resultado depende da inicialização aleatória dos pesos e da versão da biblioteca: embora a média de três redes reduza essa variabilidade, não se avaliou sua dispersão com outras sementes. Terceiro, o limite de 300 iterações do otimizador pode interromper o treinamento antes da convergência completa em algumas configurações. Por fim, uma única divisão treino-teste foi usada, de modo que as diferenças de teste entre modelos próximos, como ridge e PLS, não devem ser sobreinterpretadas.

REFERÊNCIAS

[1] M. Kuhn and K. Johnson, *Applied Predictive Modeling*. New York, NY, USA: Springer, 2013.

[2] I.-K. Yeo and R. A. Johnson, "A new family of power transformations to improve normality or symmetry," *Biometrika*, vol. 87, no. 4, pp. 954–959, 2000.

[3] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[4] A. E. Hoerl and R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970.

[5] S. Wold, M. Sjöström, and L. Eriksson, "PLS-regression: A basic tool of chemometrics," *Chemometrics Intell. Lab. Syst.*, vol. 58, no. 2, pp. 109–130, 2001.

[6] P. Geladi and B. R. Kowalski, "Partial least-squares regression: A tutorial," *Anal. Chim. Acta*, vol. 185, pp. 1–17, 1986.

[7] K. Hornik, M. Stinchcombe, and H. White, "Multilayer feedforward networks are universal approximators," *Neural Netw.*, vol. 2, no. 5, pp. 359–366, 1989.

[8] D. C. Liu and J. Nocedal, "On the limited memory BFGS method for large scale optimization," *Math. Program.*, vol. 45, pp. 503–528, 1989.